



UNIVERSIDAD MAYOR DE SAN ANDRÉS

Caso de estudio 1: Machine Learning

Cotización inteligente de fletes de exportación · Gravetal Bolivia

Metodología CRISP-DM · Modelo Ridge en producción · Snowflake + Python + App offline

Materia: _____

Docente: _____

Dupla 2 — Integrante 1: _____

Dupla 2 — Integrante 2: _____

R² 0.905
test

MAE \$26.55
test

MAPE 16 %
test

Índice y control documental

- | | |
|--|--|
| 1. Comprensión del negocio (CRISP-DM 1) | 7) |
| 2. Datos y dataset (CRISP-DM 2 · Crit. 1) | 8. Visualizaciones (Crit. 8) |
| 3. Análisis de variables (Crit. 11) | 9. Valor para el negocio (Crit. 6) |
| 4. Preparación: train / test (CRISP-DM 3 · Crits. 2–3) | 10. Datos en la nube (Crit. 10) |
| 5. Modelado (CRISP-DM 4 · Crit. 5) | 11. Despliegue (CRISP-DM 6) |
| 6. Validación (Crit. 9) | 12. Monitoreo y mantenimiento (CRISP-DM 6) |
| 7. Métricas y resultados (CRISP-DM 5 · Crits. 4 y | 13. Cierre, futuro y anexos |

Control de versiones

Versión	Fecha	Cambio
v1	Oct-2026	Ridge $\alpha=0,1$, MAE \$26.55, R^2 0.905, app verificada 5/5

Cómo leer este informe

Cada capítulo mapea una fase CRISP-DM y los 11 criterios del programa Python. Los gráficos se generaron con matplotlib desde los resultados medidos.

Resumen ejecutivo

Gravetal exporta harina y aceite de soya; el flete define gran parte del margen. Este proyecto convierte 20 000 envíos históricos en un **cotizador supervisado** con **MAE \$26.55 y R^2 0.905**, 74.1 % mejor que el baseline de la media.

74.1 %
mejora vs media

17 000
filas train

5/5
réplica JS ✓

- **Entrega:** modelo Ridge verificado + app HTML offline (predicción, lotes CSV, dashboards, monitoreo).
- **Garantía:** split cronológico 70/15/15, validación temporal de 3 folds, réplica JS vs sklearn 5/5 (diff < 0,01).
- **Valor:** cotización en segundos con banda ± 1 MAE (\$53.10 de ancho); re-entrenamiento si MAE mensual > \$35 o deriva > 15 %.
- **Honestidad:** sintéticos en cuarentena (contrato 1, ventas 2025, fechas 1990/2099) y frentes nulos documentados (calidad $AUC \approx 0.5$, retrasos $R^2 \approx 0$).

Comprensión del negocio (CRISP-DM 1)

Objetivo: reducir el error de cotización para proteger el margen del crush (≈ 80 USD/TN). **Tra-ducción:** regresión del `costo_flete_usd` con 8 features de ruta, equipo y mes. Métrica principal MAE (dólares); secundarias R^2 y MAPE.

MAE < \$35
logrado \$26.55 ✓

R^2 > 0,80
logrado 0.905 ✓

MAPE < 20 %
logrado 16 % ✓

Decisión que habilita: cotizar un embarque en segundos con banda de confianza en vez de estimar a mano (error > \$100). Regla: banda superior bajo el precio del cliente → cerrar; si la cruza → renegociar ruta/mes/transporte o escalar.

Datos y dataset (CRISP-DM 2 · Criterio 1)

Origen: Snowflake WMNAMCT-LN60692 / ARQUI1.CAPA_BRONCE, ENVIO + TRANSPORTE unidas por ID_TRANSPORTE, vía COMPUTE_WH. Una sola query con JOIN + filtro (> 0); sin credenciales en código.

Variable	Tipo	Rol	Calidad
distancia_km	numérica	feature	> 0; media train 1483.4
duracion_h	numérica	feature	de fechas; media 9.38
capacidad_tn	numérica	feature	media 412.2; atípicos vigilados
mes	1–12	feature	estacionalidad de campaña
tipo / origen / destino / bandera	categóricas	features	4 / 3 / 5 / 4 niveles; nulos → FALTA
costo_flete_usd	numérica	target	> 0; sin leakage a features

EDA: 20 000 filas útiles; colas a la derecha (rutas largas caras); correlación distancia–costo dominante; duplicados y outliers por rango; artefactos sintéticos en cuarentena.

Análisis de variables (Criterio 11)

Variable	Media	Lectura
distancia_km	1483.36	Driver #1 (coef. +8.76)
duracion_h	9.38	Débil ceteris paribus
capacidad_tn	412.22	Efecto escala leve
mes	6.50	Estacionalidad suave

**Distancia >> destino/origen >> resto
importancia del modelo**

Niveles: tipo {BARCAZA, CAMION, CAMION CISTERNA, FERROVIARIO}; origen {Puerto Quijarro, San Julián, Warnes}; destino {Buenos Aires, Puerto Aguirre, Puerto Quijarro, Rosario, Santos}; bandera {Argentina, Bolivia, Brasil, Paraguay}. Sin multicolinealidad problemática (Ridge la regulariza de todos modos).

Preparación: train / test (CRISP-DM 3 · Criterios 2–3)

- **Limpieza:** costo > 0, distancia > 0; coerción a float; “FALTA” en nulos categóricos; sin imputar el target.
- **Split cronológico 70/15/15** (≈17 000 train): respeta campañas; el test es el bloque final, nunca visto.
- **Sin leakage:** mediana y estandarizado ajustados **solo en train**; one-hot con `handle_unknown=ignore`; α elegida solo en validación.
- **Pipeline reproducible:** `SimpleImputer(median) → StandardScaler + OneHotEncoder → Ridge`; `random_state fijo`; `scikit-learn==1.8.0`.

train (70%) → validación temporal → test final intocable (15%)

Modelado (CRISP-DM 4 · Criterio 5)

Campeón: Ridge $\alpha=0,1$ (grilla logarítmica de 20 valores $10^{-1} \dots 10^5$): señal mayormente lineal + regularización del one-hot, simple, estable y exportable a JSON exacto (20 coeficientes + intercepto 156.48).

Modelo	Rol	MAE	Mejora vs media
Ridge	productivo	26.55	74.1 %
HGB	retador	26.41	74.2 %
RF	retador	26.65	74.0 %
Media	baseline	102.38	—

Solo ML supervisado (sin ARIMA por política; baselines ingenuos solo etiquetados). Los tres ML empatan; Ridge queda por simplicidad y estabilidad.

Validación (Criterio 9)


TimeSeriesSplit de 3 folds en train para elegir α ; test evaluado una sola vez. Train $\approx$ test (R^2 0.905): sin sobreajuste; +74.1 % vs baseline: capacidad suficiente.

Caso	sklearn	JS	Diff
1	368.44	368.44	0.001
2	205.79	205.79	0.001
3	242.86	242.86	0.003
4	69.13	69.13	0.005
5	71.99	71.99	0.005

Réplica exacta en navegador
diff máx 0.005 · 5/5 ✓


Métricas y resultados (CRISP-DM 5 · Criterios 4 y 7)

Modelo (test)	MAE ↓	R^2 ↑	MAPE ↓
Ridge	26.55	0.905	16 %
HGB	26.41	0.903	≈ 16 %
RF	26.65	0.901	≈ 16 %
Media	102.38	0.000	—






Error típico $\pm \$26,5$ por envío (16 % relativo); 90.5 % de varianza explicada. Cada cotización lleva banda ± 1 MAE (\$53.10 de ancho). Límites: rutas/países nuevos → “desconocido”; extremos fuera de rango → revisión humana.

Ejemplo real: camión P. Quijarro → Rosario (1722 km)



Visualizaciones (Criterio 8)



Gráficos matplotlib desde resultados medidos. La app suma gauge, donut, histograma de lotes y banda $\pm$ MAE por cotización.

Valor para el negocio (Criterio 6)

- **Cobertura aceite (backtest):** +53 % estrategia vs +40 % buy&hold, vol -28 %, hit-rate 0.50 declarado: gestión de riesgo, no caja mágica.
- **IoT térmico:** F1 0.60, AUC 0.87, recall ≈ 1.0 con sobre-alerta declarada.
- **Ahorro indicativo:** de $\approx \$102$ a $\approx \$27$ de error medio $\approx \$75$ por envío.

$\approx \$75\,000$ de riesgo contenido
1 000 envíos/año

Datos en la nube (Criterio 10)

- Fuente ARQUI1.CAPA_BRONCE (44/44 tablas, conteos idénticos).
- Una query con JOIN + filtro vía COMPUTE_WH.
- Sin credenciales en código (sesión / entorno).
- Scoring en navegador (sin servidor).

modelo_flete_web.json
medianas · escalas · vocabularios ·
20 coefs · α · métricas · 5 testigos

Re-entrenar = regenerar el JSON y republicar el HTML; el self-test 5/5 valida cada despliegue.

Despliegue (CRISP-DM 6)

Despligue/app_fletee.html: doble clic, sin internet, theme oscuro. Cuatro pestañas:

1. **Predecir:** 8 campos (listas 4/3/5/4) → cotización con count-up, banda $\pm$ MAE y top-3 factores del caso.
2. **Lotes CSV:** predice N filas, MAE/ R^2 si trae costo_flete_usd, histograma de 12 barras y descarga predicciones_flete.csv.
3. **Dashboards:** KPIs con count-up, gauge R^2 0.905, duelo MAE/ R^2 , cobertura, donut IoT, verificación 5 casos.
4. **Monitoreo:** deriva $> 15\%$, registro v1, plan de mantenimiento y riesgos conocidos.

Archivo de prueba: Despligue/datos_prueba_fletes.csv (12 envíos con costo; MAE simulado $\approx$ \$9.5, estado “sano”).

Monitoreo y mantenimiento (CRISP-DM 6)

Señal	Regla	Acción
MAE mensual del lote	$> \$35$ dos meses	Re-entrenar y versionar (v2)
R^2 del lote	$< 0,70$	Declarar deriva, re-entrenar
Deriva de medias	$> 15\%$ vs train	Revisar supuestos de ruta/precio
Esquema Bronce	columnas nuevas	Regenerar JSON + self-test 5/5

Riesgos vigilados: ventas 2025 contaminadas (topes $< 5000 / < \$2000$), contrato 1 e IDs basura, fechas 1990/2099, voltaje IoT constante 3.3. **Registro:** v1 (29/9) Ridge $\alpha=0,1$, MAE \$26.55, R^2 0.905, sklearn 1.8.0.

Cierre, futuro y anexos

Conclusión: cumple las tres metas, generaliza en test cronológico y opera offline con réplica exacta; segunda opinión cuantificada, no orden automática.

Limitaciones honestas: calidad de grano (AUC $\approx$ 0.5, etiqueta aleatoria), retrasos uniformes ($R^2 \approx 0$), IoT a 1 paso $\approx$ azar; sintéticos en cuarentena no vuelven al train sin auditoría.

Trabajo futuro: intervalos conformales por ru-

ta, features de combustible/temporada, calibración mensual automática.

Anexo — cuarentena: productor 525 (4.381M TN) · contrato 1 · $\approx$ 800 ventas 2025 · fechas 1990/2099 · inventario $\gg$ capacidad · IoT 5 min.

Glosario: MAE = error absoluto medio (USD). R^2 = varianza explicada. MAPE = error %. Deriva = cambio de distribución vs train.