

Cotización inteligente de fletes de exportación

Informe final del proyecto de Machine Learning · Gravetal Bolivia

Metodología CRISP-DM · Modelo Ridge en producción · Snowflake + Python + App offline

R² 0.905
test

MAE \$26.55
test

MAPE 16 %
test

Rubro	Detalle
Problema	Regresión: predecir <code>costo_flete.usd</code> por envío
Datos	20 000 envíos · Snowflake <code>ARQUI1.CAPA_BRONCE</code> (ENVIO + TRANSPORTE)
Modelo	Ridge $\alpha=0,1$ · scikit-learn 1.8.0 · réplica exacta JS 5/5
Despliegue	<code>Despligue/app_flete.html</code> (offline) + <code>modelo_flete.web.json</code>
Versión	v1 · Octubre 2026 · rama <code>mineria</code>

Índice y control documental

1. Comprensión del negocio (CRISP-DM 1) y 7)
2. Datos y dataset (CRISP-DM 2 · Crit. 1) 8. Visualizaciones (Crit. 8)
3. Análisis de variables (Crit. 11) 9. Valor para el negocio (Crit. 6)
4. Preparación: train / test (CRISP-DM 3 · Crits. 2–3) 10. Datos en la nube (Crit. 10)
5. Modelado (CRISP-DM 4 · Crit. 5) 11. Despliegue (CRISP-DM 6)
6. Validación (Crit. 9) 12. Monitoreo y mantenimiento (CRISP-DM 6)
7. Métricas y resultados (CRISP-DM 5 · Crits. 4) 13. Cierre, futuro y anexos

Control de versiones

Versión	Fecha	Cambio
v1	Oct-2026	Ridge $\alpha=0,1$, MAE \$26.55, R^2 0.905, app verificada 5/5

Resumen ejecutivo

Gravetal exporta harina y aceite de soya; el flete define gran parte del margen. Este proyecto convierte 20 000 envíos históricos en un **cotizador supervisado** con **MAE \$26.55** y R^2 **0.905**, 74 % mejor que el baseline de la media.

- **Entrega:** modelo Ridge verificado + app HTML offline (predicción, lotes CSV, dashboards, monitoreo).
- **Garantía:** split cronológico 70/15/15, validación temporal de 3 folds, réplica JS vs sklearn 5/5 (diff < 0,01).
- **Valor:** cotización en segundos con banda ± 1 MAE; re-entrenamiento si MAE mensual > \$35 o deriva > 15 %.
- **Honestidad:** sintéticos en cuarentena (contrato 1, ventas 2025, fechas 1990/2099) y frentes nulos documentados (calidad AUC $\approx$ 0.5).

Comprensión del negocio (CRISP-DM 1)

Objetivo: reducir el error de cotización para proteger el margen del crush (≈ 80 USD/TN). **Traducción:** regresión del `costo_flete_usd` con 8 features de ruta, equipo y mes. Métrica principal MAE (dólares); secundarias R^2 y MAPE.

MAE < \$35
logrado \$26.55 ✓

R^2 > 0,80
logrado 0.905 ✓

MAPE < 20 %
logrado 16 % ✓

Dimensión	Estado
Latencia	Cotización en segundos, offline ✓
Alcance	4 listas con 4/3/5/4 opciones + 4 numéricas ✓

Datos y dataset (CRISP-DM 2 · Criterio 1)

Origen: Snowflake WMNAMCT-LN60692 / ARQUI1.CAPA_BRONCE, ENVIO + TRANSPORTE unidas por ID_TRANSPORTE.

Variable	Tipo	Rol	Calidad
distancia_km	numérica	feature	> 0; media 1483.4
duracion_h	numérica	feature	de fechas; media 9.38
capacidad_tn	numérica	feature	media 412.2
mes	1–12	feature	estacionalidad
tipo / origen / destino / bandera	categorías	features	4 / 3 / 5 / 4 niveles; nulos → FALTA
costo_flete_usd	numérica	target	> 0; sin leakage

EDA: 20 000 filas; colas a la derecha (rutas largas caras); correlación distancia–costo dominante; duplicados y outliers por rango; sintéticos en cuarentena.

Análisis de variables (Criterio 11)

Variable	Media	Lectura
distancia_km	1483.36	Driver #1 (coef. +8.76)
duracion_h	9.38	Débil ceteris paribus
capacidad_tn	412.22	Escala leve
mes	6.50	Estacionalidad suave

Distancia >> **des-**
tino/origen >> **resto**
importancia del modelo

Niveles: tipo {BARCAZA, CAMION, CAMION CISTERNA, FERROVIARIO}; origen {Puerto Quijarro, San Julián, Warnes}; destino {Buenos Aires, Puerto Aguirre, Puerto Quijarro, Rosario, Santos}; bandera {Argentina, Bolivia, Brasil, Paraguay}. Sin multicolinealidad problemática.

Preparación: train / test (CRISP-DM 3 · Criterios 2–3)

- **Limpieza:** costo > 0, distancia > 0; coerción a float; “FALTA” en nulos categóricos.
- **Split cronológico 70/15/15** ($\approx 17\,000$ train): el test es el bloque final, nunca visto.
- **Sin leakage:** mediana y estandarizado ajustados **solo en train**; one-hot con `handle_unknown=ignore`.
- **Pipeline:** `SimpleImputer(median)` $\rightarrow$ `StandardScaler` + `OneHotEncoder` $\rightarrow$ `Ridge`; `random_state` fijo; `scikit-learn==1.8.0`.

train (70 %) $\rightarrow$ validación temporal $\rightarrow$ test final intocable (15 %)

Modelado (CRISP-DM 4 · Criterio 5)

Campeón: Ridge $\alpha=0,1$ (grilla de 20 valores $10^{-1} \dots 10^5$): señal mayormente lineal + regularización del one-hot, simple y exportable a JSON exacto.

Modelo	Rol	Test
Ridge	productivo	MAE 26.55 / R^2 0.905
HGB	retador	MAE 26.41 / R^2 0.903
RF	retador	MAE 26.65 / R^2 0.901
Media	baseline	MAE 102.38 / R^2 0.000

Solo ML supervisado (sin ARIMA por política; baselines ingenuos solo etiquetados). 20 coeficientes + intercepto 156.48.

Validación (Criterio 9)

TimeSeriesSplit de 3 folds en train para elegir α ; test evaluado una vez. Train $\approx$ test (R^2 0.905): sin sobreajuste; +74 % vs baseline: capacidad suficiente.

Caso	sklearn	JS	Diff
1	368.44	368.44	0.001
2	205.79	205.79	0.001
3	242.86	242.86	0.003
4	69.13	69.13	0.005
5	71.99	71.99	0.005


Réplica exacta JS
diff < 0,01 · 5/5 ✓

Métricas y resultados (CRISP-DM 5 · Criterios 4 y 7)

Modelo (test)	MAE ↓	R^2 ↑	MAPE ↓
Ridge $\alpha=0,1$	26.55	0.905	16 %
HGB	26.41	0.903	≈ 16 %
RF	26.65	0.901	≈ 16 %
Media	102.38	0.000	—

Error típico $\pm \$26,5$ por envío; 90.5 % de varianza explicada. Cada cotización lleva banda ± 1 MAE.
Límites: rutas/países nuevos $\rightarrow$ “desconocido”; extremos fuera de rango $\rightarrow$ revisión humana.

Visualizaciones (Criterio 8)



Valor para el negocio (Criterio 6)

- **Decisión habilitada:** cotizar en segundos con banda de confianza en vez de estimar a mano (error > \$100).
- **Regla:** banda superior bajo el precio del cliente → cerrar; si la cruza → renegociar o escalar.
- **Ahorro indicativo:** de $\approx \$102$ a $\approx \$27$ de error medio $\approx \$75$ por envío.

$\approx \$75\,000$ de riesgo contenido
1 000 envíos/año

Datos en la nube (Criterio 10)

- Fuente Snowflake ARQUI1.CAPA_BRONCE (44/44 tablas, conteos idénticos).
- Una query con JOIN + filtro vía COMPUTE_WH; sin credenciales en código.
- `modelo_flete_web.json` versionado: medianas, escalas, vocabularios, 20 coeficientes, α , métricas y 5 casos testigo.
- Scoring en navegador (sin servidor); re-entrenar = regenerar el JSON.

Despliegue (CRISP-DM 6)

Despliegue/app_flete.html: doble clic, sin internet. Cuatro pestañas:

1. **Predecir:** 8 campos (listas 4/3/5/4) → cotización con count-up, banda $\pm$ MAE y top-3 factores.
2. **Lotes CSV:** predice N filas, MAE/ R^2 si trae `costo_flete.usd`, histograma y descarga.
3. **Dashboards:** KPIs, gauge R^2 , duelo MAE/ R^2 , cobertura (+53 % vs +40 %), IoT (F1 0.60, AUC 0.87), 5 casos.
4. **Monitoreo:** deriva, versiones, mantenimiento y riesgos.

Monitoreo y mantenimiento (CRISP-DM 6)

Señal	Regla	Acción
MAE mensual	> \$35 dos meses	Re-entrenar (v2)
R^2 del lote	< 0,70	Declarar deriva
Deriva de medias	> 15 % vs train	Revisar supuestos
Esquema Bronce	columnas nuevas	Regenerar JSON + 5/5

Riesgos: ventas 2025, contrato 1, fechas 1990/2099, voltaje IoT 3.3. Registro: v1 (29/9) Ridge $\alpha=0,1$, MAE \$26.55, R^2 0.905, sklearn 1.8.0.

Cierre, futuro y anexos

Conclusión: cumple las tres metas, generaliza en test cronológico y opera offline con réplica exacta; segunda opinión cuantificada, no orden automática. **Limitaciones:** calidad de grano ($AUC \approx 0.5$), retrasos uniformes ($R^2 \approx 0$), IoT a 1 paso $\approx$ azar; sintéticos en cuarentena. **Futuro:** intervalos conformales por ruta, features de combustible, calibración mensual.

Anexo — cuarentena y glosario

Productor 525 (4.381M TN) · contrato 1 · ≈ 800 ventas 2025 · fechas 1990/2099 · inventario $\gg$ capacidad · IoT 5 min. MAE: error absoluto medio (USD). R^2 : varianza explicada. MAPE: error %. Deriva: cambio de distribución vs train.